

استفاده از شبکه‌ی UNet با نظارت عمیق برای تخمین فشار خون پیوسته از سیگنال فوتوپلتیسموگرافی

معصومه خالقیان^۱، سیده سمانه شجاعی لنگری^{۲*}، مریم بیگ زاده^۲

۱- گروه مهندسی برق و کامپیوتر، دانشکده هوش مصنوعی، دانشگاه خوارزمی، تهران، کرج

۲- گروه مهندسی پزشکی، پژوهشکده برق و فناوری اطلاعات، سازمان پژوهش‌های علمی و صنعتی ایران، تهران

* Corresponding Author E-mail: s.shojaie@irost.ir

چکیده

پایش فشار خون، یکی از مؤلفه‌های حیاتی برای حفظ سلامتی است. فشار خون بالا، به عنوان یک عامل خطر می‌تواند منجر به بروز حمله قلبی، سکته، نارسایی قلبی و کلیوی شود. همچنین، فشار خون پایین نیز می‌تواند خطرناک باشد و منجر به گیجی، ضعف، غش و اختلال در اکسیژن رسانی به اندام‌ها و آسیب به مغز و قلب گردد. از این رو پایش مداوم میزان فشار خون در افراد با ریسک بالا بسیار حائز اهمیت می‌باشد، به طوری که استفاده از دستگاه هولتر فشارخون به دلیل قابلیت ثبت طولانی مدت و ارزشمند اطلاعات فشارخون برای بسیاری از بیماران تجویز می‌شود. تلاش برای دستیابی به تکنیک‌های نرم افزاری و توسعه دستگاه‌های اندازه‌گیری فشارخون بدون کاف، با حفظ آسایش و راحتی بیمار، از مهمترین چالش‌هایی است که ذهن پژوهشگران را به خود اختصاص داده است. در این پژوهش یک چهارچوب یادگیری عمیق بر مبنای شبکه UNet یک‌بعدی با نظارت عمیق جهت تخمین فشار خون پیوسته از روی سیگنال فوتوپلتیسموگرافی بدون استفاده از روش کالیبراسیون فردی ارائه شده است. مدل ارائه شده بر روی بانک داده UCI برای ۹۴۲ بیمار تحت مراقبت ویژه، به میانگین خطای مطلق ۸/۸۸، ۴/۴۳ و ۳/۳۲ و انحراف معیار ۱۱/۰۱، ۶/۱۸ و ۴/۱۵ میلی‌متر جیوه به ترتیب برای فشار خون سیستول، دیاستول و فشار خون میانگین دست یافت. طبق استاندارد بین المللی BHS، روش پیشنهادی، درجه‌ی A برای فشار خون دیاستول و میانگین و نیز درجه‌ی C برای فشار خون سیستول را برآورده می‌کند. نتایج حاصل از این پژوهش حاکی از آن است که چهارچوب یادگیری عمیق پیشنهادی، پتانسیل لازم را برای تخمین کابردی فشار خون بر پایه سیگنال PPG دارد.

واژه‌های کلیدی: سیگنال فوتوپلتیسموگرافی، تخمین فشار خون، روش غیرتهاجمی، هوش مصنوعی، یادگیری عمیق، یادگیری ماشین

Using Deep Supervised UNet Network for Continuous Estimation of Blood Pressure Based on Photoplethysmography Signal

Abstract

Blood pressure monitoring is a vital component of maintaining overall health. High blood pressure values, as a risk factor, can lead to heart attacks, strokes, and heart and kidney failures. Similarly, low blood pressure values can also be dangerous, causing dizziness, weakness, fainting, and impaired oxygen delivery to organs, resulting in brain and heart damage. Consequently, continuous monitoring of blood pressure levels in high-risk individuals is very important. A Holter blood pressure monitoring device is prescribed for many patients due to its ability to provide long-term and valuable blood pressure data. The pursuit of software techniques and the development of cuffless blood pressure measurement devices, while ensuring patient comfort and convenience, are among the significant challenges that researchers are focusing on. In this study, a deep learning framework based on the UNet network is proposed for continuous blood pressure estimation from photoplethysmography signals. The proposed model was evaluated on the UCI database, involving 942 patients under intensive care, and achieved mean absolute errors of 8.88, 4.43, and 3.32, with standard deviations of 11.01, 6.18, and 4.15, respectively, for systolic, diastolic, and mean arterial blood pressure values. According to the international BHS standard, the proposed method meets grade A criteria for diastolic and mean blood pressure estimations and grade C for systolic blood pressure estimation. The results of this study demonstrate that the suggested deep learning framework has the necessary potential for blood pressure estimation from PPG signals in real-world applications.

Keywords: Photoplethysmography signal, Blood pressure estimation, Non-invasive technique, Artificial intelligence, Deep learning, Machine learning

۱. مقدمه

فشار خون یکی از مهم‌ترین سیگنال‌های حیاتی بدن است. اندازه‌گیری آن با توجه به دربرگیری اطلاعات فیزیولوژیکی مربوط به عملکرد قلب دارای اهمیت بسیار در جامعه پزشکی است. با توجه به اینکه فشار خون غیرطبیعی عموماً عارضه یا علامت آنی ندارد، بسیاری از افراد از مشکل خود بی‌خبر هستند. به همین دلیل پایش پیوسته فشارخون و ساخت هر چه دقیق‌تر و کاربردی‌تر دستگاه‌های هولتر برای اندازه‌گیری فشار خون در دنیای امروز از اهمیت بالایی برخوردار است. استفاده‌ی طولانی مدت از دستگاه هولتر فشار خون با کاف ممکن است با برخی مشکلات همچون ایجاد محدودیت در فعالیت‌های روزمره، آسیب به شریان، ایجاد ناراحتی و مزاحمت برای خواب بیماران و ... همراه باشد. با توجه به مشکلات مطرح شده، توسعه‌ی دستگاه‌های اندازه‌گیری فشار خون بدون استفاده از کاف و با حفظ آسایش بیمار یکی از چالش‌های مهم در حوزه پزشکی است. تاکنون تلاش‌های فراوانی در جهت ارائه روش‌های غیر تهاجمی برای اندازه‌گیری فشار خون صورت گرفته است [۱]، [۲].

روش‌های غیرتهاجمی برای اندازه‌گیری فشار خون معمولاً بر پایه‌ی اندازه‌گیری و تحلیل سیگنال‌های حیاتی مانند الکتروکاردیوگرافی (ECG)^۱ و فوتوپلتیسموگرافی (PPG)^۲ تمرکز دارند [۳]. فوتوپلتیسموگرافی یک روش نورسنجی است که برای اندازه‌گیری تغییرات حجم خون در عروق سطحی استفاده می‌شود. این تکنیک بر اساس اصل تغییرات نوری بر اثر جذب و پراکندگی نور توسط بافت‌های بیولوژیکی کار می‌کند. هنگامی که نور از منبع نور به پوست می‌تابد، بخشی از این نور توسط بافت‌های پوستی جذب می‌شود و بخشی دیگر بازتاب می‌شود. این نور بازتاب شده توسط دیود نوری دریافت و به سیگنال الکتریکی تبدیل می‌شود. سیگنال ECG نیز بیان‌گر فعالیت الکتریکی قلب است و به کمک الکترودهای فلزی از سطح پوست ثبت می‌گردد [۴]. تحقیقات نشان می‌دهد که این دو سیگنال می‌توانند به عنوان نماینده‌هایی از فعالیت قلبی و عروقی استفاده شوند و فشار خون را نیز تخمین بزنند. برخی از محققین از این دو سیگنال به صورت همزمان استفاده می‌کنند تا دقت بیشتری در تخمین فشار خون حاصل شود.

با توجه به اینکه تخمین فشار خون براساس به‌کارگیری دو سیگنال ECG و PPG نیازمند دستگاهی با قابلیت ثبت همزمان دو سیگنال می‌باشد، ترجیح ما در این پژوهش، استفاده از تنها یک سیگنال جهت ارتقای کارایی ابزارهای موجود بدون تحمیل هزینه‌ی اضافی برای حل معضل اندازه‌گیری فشار خون به صورت مداوم می‌باشد. دستگاه‌های PPG به دلیل مقرون به صرفه بودن و قابل حمل بودن، مدت‌هاست که برای اندازه‌گیری میزان ضربان قلب و میزان اشباع اکسیژن خون استفاده می‌شوند. با توجه به آن که ثبت PPG به صورت غیر تهاجمی و با استفاده از یک سنسور ساده انجام می‌شود، استفاده از آن در ابزارهای سنجش سلامت (به ویژه تجهیزات پرتابل و گجت‌های پوشیدنی) بسیار متداول است. همچنین در مقایسه با سیگنال ECG که ثبت آن نیاز به تجهیزات پیچیده و نصب الکتروود در شرایط آزمایشگاهی دارد، PPG به سادگی و در هر شرایطی قابل ثبت است.

در تحقیقات اخیر در حوزه‌های مرتبط، استفاده از الگوریتم‌های یادگیری ماشینی و شبکه‌های عصبی عمیق برای تحلیل سیگنال‌های زیستی بسیار مورد توجه قرار گرفته است. نتایج این تحقیقات به طور کلی نشان می‌دهد که با انتخاب و آموزش صحیح این الگوریتم‌ها و در اختیار داشتن داده‌ی کافی و مناسب، می‌توان به تخمین دقیق‌تری از فشار خون بیماران رسید. برای تخمین فشار خون از روی سیگنال PPG، روش‌های متنوعی وجود دارد که عمدتاً به دو دسته تقسیم می‌شوند: روش‌های تحلیلی و روش‌های مبتنی بر داده.

از مهم‌ترین روش‌های تحلیلی تخمین فشارخون، محاسبه شاخص‌هایی مانند زمان گذار پالس^۳ (PTT) و زمان رسیدن موج نبض^۴ (PAT) است. در عمل، برای تخمین پارامترهای PTT و PAT می‌توان از دو سیگنال PPG استفاده کرد [۵]، [۶]، [۷]. همچنین می‌توان از ترکیبی از سیگنال PPG با سیگنال ECG و یا سیگنال حاصل از حسگرهای مغناطیسی و حسگر امپدانس سنجی استفاده نمود [۸]. با این حال، استفاده از دو سیگنال ورودی و دو حسگر در دو نقطه مختلف بدن نیازمند محدودیت حرکت فرد است و این مسئله باعث محدودیت کاربردهای عملی این تکنیک می‌شود. از طرفی، نتایج حاصل از این روش‌ها

^۱ Electrocardiography

^۲ Photoplethysmography

^۳ Pulse Transit Time (PTT)

^۴ Pulse Arrival Time (PAT)

دقت لازم در تخمین فشارخون را ندارند و نمی‌توانند به خوبی پیچیدگی سیستم قلب و عروق، گردش خون و تولید فشارخون در بدن را مدل کنند. هم چنین، تعداد ویژگی‌های به کار رفته به عنوان ورودی در این مدل‌ها بسیار محدود و ناکافی هستند.

روش‌های مبتنی بر داده معمولاً با استفاده از الگوریتم‌های یادگیری ماشین و فنون تحلیل داده، اطلاعات موجود در سیگنال PPG را بررسی و تحلیل می‌کنند تا فشار خون را تخمین بزنند [۹]، [۱۰]، [۱۱]. روش‌های سنتی یادگیری ماشین شامل الگوریتم‌های استخراج ویژگی از سیگنال PPG و تخمین زنده‌های^۱ کلاسیک همچون ماشین‌های بردار پشتیبان، درخت تصمیم، جنگل تصادفی و ... می‌باشند [۱۲] [۱۳]. اما از آنجا که سیگنال PPG بسیار آغشته به نویز بوده، استخراج ویژگی به صورت دستی از آن دشوار می‌باشد. از طرفی سیگنال PPG تحت تأثیر تغییرات فیزیولوژیکی مانند ضربان قلب، فشار خون و رفتار عروق قرار می‌گیرد که ممکن است باعث تغییر در الگوهای سیگنال و ایجاد مشکل در استخراج ویژگی‌ها شوند. به همین دلیل، در مطالعات اخیر از روش‌های نوین هوش مصنوعی که مبتنی بر استخراج خودکار ویژگی‌ها است، برای استخراج ویژگی‌های مفید از سیگنال PPG برای تخمین فشار خون استفاده شده است [۱۴]. در روش‌های نوین هوش مصنوعی همچون یادگیری عمیق، الگوریتم‌های یادگیری بدون این که صراحتاً برنامه‌ریزی شوند، ارتباط بین متغیرها را آموخته و مدل را می‌سازند.

به طور خلاصه، می‌توان گفت استفاده از سیگنال‌های حیاتی مانند ECG و PPG برای تخمین فشار خون بدون استفاده از کاف امیدوار کننده است، اما هنوز نیاز به پژوهش بیشتری در این حوزه و توسعه‌ی فناوری‌های نوین داریم تا بتوانیم به روش‌های دقیق و قابل اعتمادتری برای اندازه‌گیری فشار خون بدون کاف دست یابیم.

در این پژوهش یک مدل یادگیری ماشین با عنوان UNet یک‌بعدی^۲ با نظارت عمیق^۳ برای تخمین فشار خون پیوسته طراحی شده است. نظارت عمیق یک تکنیک است که با هدایت فرآیند یادگیری لایه‌های مخفی، خطاهای کلی را کاهش می‌دهد. اصل این روش بر این اساس است که علاوه بر خروجی نهایی مدل، خروجی‌های میانی نیز برای محاسبه زیان^۴ شبکه استفاده می‌شوند و این زیان‌ها در محاسبه وزن‌های کاهش‌یافته‌ی شبکه در نظر گرفته می‌شوند. این خروجی‌های میانی ممکن است در لایه‌های مختلف مدل قرار گیرند و باعث شوند که فرآیند یادگیری بهتر هدایت شود و خطاهای کلی در مدل کاهش یابد [۱۵]. روش نظارت عمیق قابل استفاده در انواع معماری‌ها و مدل‌های عمیق مانند شبکه‌های عصبی کانولوشنی (CNN)^۵، شبکه‌های بازگشتی (RNN)^۶ و شبکه‌های مولد متخاصم (GAN)^۶ است [۱۶].

در ادامه، در بخش ۲، روش تحقیق شامل پیش پردازش داده و روش رگرسیون اعمال شده جهت تخمین فشار خون به تفصیل شرح داده خواهد شد. در بخش ۳ نتایج این پژوهش را با معیارهای ارزیابی مختلف مورد بررسی قرار داده و در نهایت در بخش ۴ به بحث و نتیجه‌گیری و مقایسه با دیگر پژوهش‌های این حوزه می‌پردازیم.

۲. روش کار

چهارچوب کلی روش پیشنهادی برای تخمین فشارخون در شکل ۱ نمایش داده شده است. در این بخش ابتدا به معرفی مجموعه‌داده‌ی به کار رفته برای آموزش مدل پرداخته و سپس روش به کار برده شده برای پیش‌پردازش داده‌ها و حذف نویز از داده‌ها را شرح می‌دهیم. در پایان نیز به توضیح مدل به کار برده شده برای پیش‌بینی فشارخون می‌پردازیم.

^۱ Pulse Arrival Time (PAT)


^۲ Deep supervision-based 1D-UNet

^۳ Loss

^۴ Convolutional Neural Network

^۵ Recurrent Neural Network

^۶ Generative Adversarial Network



شکل ۱: چهارچوب کلی روش پیشنهادی برای تخمین فشار خون پیوسته و پارامترهای آن. منظور از ABP سیگنال فشار خون شریانی است.

۱-۲. مجموعه دادگان

در این مطالعه، از مجموعه داده‌ی UCI که به نام Cuff-Less Blood Pressure Estimation نیز شناخته می‌شود و در پایگاه داده‌ی فیزیونت قابل دستیابی است، استفاده کردیم [۱۷]. در حقیقت این مجموعه داده، نسخه‌ی فیلتر شده‌ی داده‌ی MIMIC-III بوده و شامل ۱۲'۰۰۰ نمونه از اطلاعات همزمان ECG، PPG و فشار خون شریانی (ABP)^۱ می‌باشد که از ۹۴۲ بیمار تحت مراقبت ویژه با نرخ نمونه برداری ۱۲۵ هرتز جمع آوری شده است. خلاصه‌ای از اطلاعات آماری مربوط به فشار خون این بانک داده در جدول ۱ آمده است. قابل ذکر است که فشار خون سیستول (SBP)^۲، حداکثر فشار درون سرخرگ در زمان انقباض قلب و فشارخون دیاستول (DBP)^۳ حداقل فشار درون رگ بدن در زمان استراحت قلب است. فشار خون میانگین (MAP)^۴ طبق رابطه‌ی (۱) بر حسب فشار خون سیستول و دیاستول محاسبه می‌شود.

$$MAP = \frac{(SBP + 2DBP)}{3} \quad (1)$$

جدول ۱: اطلاعات آماری از بانک داده UCI شامل مقادیر میانگین و انحراف معیار کمیت‌های SBP، DBP و MAP.

	Min (mmHg)	Max (mmHg)	Mean (mmHg)	Std (mmHg)
SBP	۷۱,۸۱	۱۹۹,۹۸	۱۴۱,۰۳	۲۵,۶۴
DBP	۵۰	۱۴۸,۲۴	۵۷,۸۰	۹,۳۱
MAP	۵۷,۳۷	۱۶۰,۵۶	۸۵,۵۴	۱۱,۹۵

۲-۲. پیش پردازش دادگان


لازم به ذکر است که داده مورد استفاده در این پژوهش پیشتر توسط آقای کاجویی و همکاران [۱۸] مورد پیش پردازش اولیه قرار گرفته است و ما تنها از چند مرحله‌ی تکمیلی برای آماده‌سازی داده‌ها جهت پردازش‌های بعدی استفاده کرده‌ایم که این مراحل شامل قطعه‌بندی سیگنال، حذف نویز، و نرمال‌سازی داده‌ها می‌باشد. مراحل کار به صورت خلاصه در شکل ۲ نمایش داده شده است که در ادامه به توضیح مختصری از آن می‌پردازیم.

^۱ Atrial Blood Pressure

^۲ Systolic Blood Pressure

^۳ Diastolic Blood Pressure

^۴ Mean Atrial Pressure



شکل ۲: مراحل پیش پردازش

در ابتدای مرحله‌ی پیش پردازش، سیگنال‌های PPG و ABP به صورت مستقل به بخش‌های ۱۰۲۴ نمونه‌ای (با توجه به نرخ نمونه برداری ۱۲۵ هرتز، معادل ۸/۱۹۲ ثانیه)، تقسیم‌بندی می‌شوند. سپس برای حذف نویز از سیگنال، از یک فیلتر باترورت با فرکانس قطع ۰/۱ و ۳۰ هرتز استفاده می‌شود [۱۳].

در ادامه‌ی فرآیند پیش‌پردازش، نرمال سازی داده‌ها صورت می‌گیرد. نرمال‌سازی داده‌ی ورودی و خروجی در شبکه‌های عمیق یکی از مراحل مهم پیش‌پردازش داده است. این فرایند شامل تبدیل داده‌های ورودی و خروجی به یک مقیاس مشخص است که بهینه‌سازی عملکرد شبکه را تسهیل می‌کند. برای بهبود و تسریع روند آموزش و جلوگیری از مشکل "غرق شدن در وزن‌های بزرگ" نرمال سازی داده‌ها در بازه‌ی [۰، ۱] برای هر دو سیگنال ABP و PPG انجام گرفت. البته شایان ذکر است که در ارزیابی نتایج، عمل عکس نرمال سازی بر روی مقادیر تخمینی فشار خون انجام شد تا مقایسه در حالت واقعی صورت پذیرد.

بعد از پایان مراحل پیش پردازش، برای هر پنجره‌ی زمانی (هر قطعه از سیگنال) یک تخمین از فشارخون سیستولیک و یک تخمین از فشارخون دیاستولیک بر اساس سیگنال ABP (خروجی) استخراج می‌شود. این اعداد در نهایت در ارزیابی و گزارش نتایج تخمین در بخش نتایج مورد استفاده قرار می‌گیرند. لازم به یادآوری است که در سیگنال ABP، قله‌ها فشارخون سیستولیک و دره‌ها فشارخون دیاستولیک را نشان می‌دهند.

۳-۲. مدل رگرسیون

در این پژوهش از مدل رگرسیون تخمین‌گر "سیگنال به سیگنال" استفاده شده است. لازم به ذکر است که مدل سیگنال به سیگنال شامل مدل‌هایی است که از سیگنال PPG، سیگنال ABP را تخمین می‌زنند. شبکه‌ی UNet یک مدل رگرسیون سیگنال به سیگنال می‌باشد که برای تخمین سیگنال فشار خون از روی سیگنال PPG، استفاده می‌شود. معماری UNet از مجموعه‌ای از شبکه‌های عصبی کانولوشنل تشکیل شده است که شامل یک انکدر (برای کاهش نمونه برداری) و یک دیکودر (برای افزایش نمونه برداری) با اتصالات پرش می‌باشد. اگرچه معماری UNet در اصل برای تقسیم بندی معنایی تصاویر طراحی شده است، اما در هدف ما، از آن برای بازسازی سیگنال‌های یک‌بعدی استفاده می‌کنیم که در اصل یک وظیفه‌ی رگرسیون یک به یک است. بنابراین، در اینجا تمام عملیات کانولوشن دو بُعدی، ادغام^۲ و افزایش نمونه‌برداری^۳ با نسخه‌ی یک‌بعدی خود جایگزین می‌شوند. برای تولید خروجی رگرسیونی، لایه‌ی کانولوشن نهایی از تابع فعال‌سازی خطی استفاده می‌کند. علاوه بر این، ما در شبکه‌ی UNet خود همان‌طور که در شکل ۳ مشاهده می‌شود، نظارت عمیق را اعمال می‌کنیم. نظارت عمیق تکنیکی است که با هدایت فرآیند یادگیری لایه‌های مخفی، خطاهای کلی شبکه را کاهش می‌دهد. در UNet یک‌بعدی طراحی شده با نظارت عمیق، قبل از هر عملیات افزایش نمونه‌برداری در دیکودر، یک خروجی میانی محاسبه می‌کنیم که نسخه‌ی زیرنمونه‌برداری^۴ شده‌ای از سیگنال خروجی واقعی است. زیان‌ها^۵ با وزن‌های کاهشی تدریجی محاسبه می‌شوند. این زیان‌های کمکی، یادگیری لایه‌های مخفی را راهبری می‌کنند و خروجی نهایی بهتری را تولید می‌کنند.

^۱ Signal to Signal

^۲ Pooling

^۳ Upsampling

^۴ Sub-sampled

^۵ Losses

در طراحی مدل UNet، تعداد فیلترها به صورت مضرب‌های ۶۴ انتخاب شدند، به این معنا که از مقادیر (۶۴، ۱۲۸، ۲۵۶، ۵۱۲) بهره برده‌ایم. برای طراحی شبکه از پیکربندی‌های استاندارد لایه‌های کانولوشن و ادغام استفاده کرده‌ایم. در لایه‌های کانولوشن، اندازه‌ی فیلتر برابر با ۳ انتخاب شده است، در حالی که طول گام برابر با ۱ تنظیم گردیده است. پس از هر لایه‌ی کانولوشن، از تابع فعال‌ساز غیرخطی ReLU استفاده شده است. لایه‌ی ادغام حداکثری^۱ در این معماری دارای اندازه فیلتر ۲×۱ با اندازه گام ۲ است. به طور مشابه، در لایه‌های افزایش نمونه‌برداری، اندازه‌ی پنجره برابر با ۲ انتخاب گردید.

در تعلیم مدل مورد نظر از میانگین خطای مطلق (MAE)^۲ به عنوان تابع هزینه استفاده شده است. برای کاهش هزینه از بهینه ساز ADAM با پارامترهای پیش فرض در مقاله‌ی اصلی استفاده کردیم [۱۹]. در روش ADAM، نرخ یادگیری به صورت تطبیقی تنظیم می‌شود، به این معنی که این الگوریتم در طول فرآیند آموزش نرخ یادگیری را برای هر کدام از پارامترها به طور مستقل و بر اساس تخمین‌های گرادیان‌ها تنظیم می‌کند. مدل با ۱۰۰ دوره‌ی آموزشی^۳ و برای اندازه‌ی دسته^۴ ۲۵۶ و با توقف زودهنگام برای هر ۱۰ دوره آموزش دیده است.

همان‌طور که اشاره شد، در تعلیم مدل، از مکانیزم نظارت عمیق استفاده شد به این معنی که ضرر لایه‌های میانی و نهایی به منظور بازگشت گرادیان ترکیب شده و به طرز موثری تأثیر محو گرادیان را کاهش داده و کارایی یادگیری را بهبود می‌بخشد و بهینه‌سازی را تسریع می‌کند. معادله‌ی (۲) تابع زیان هر تکرار از نظارت عمیق را به شرح زیر ارائه می‌دهد که در آن L تابع زیان اصلی بوده و نمایانگر مقدار زیانی است که توسط دیکودر نهایی خروجی می‌شود. L_1 ، L_2 و L_3 به عنوان تابع‌های زیان های کمکی تعریف شده‌اند، به معنای مقدار زیانی که توسط دیکودرهای میانی خروجی می‌شود. پارامتر α ضریب نظارت عمیق است. از آنجایی که لایه‌های عمیق معمولاً ویژگی‌های پیچیده‌تری نسبت به لایه‌های کم عمق دارند، ما می‌توانیم با تخصیص وزن بالاتر به زیان خروجی شبکه عمیق، دقت تخمین خروجی را بهبود بخشیم. در این مقاله، پارامتر α هر ۱۰ دوره بر اساس فرمول $\alpha = 0.8 \times \alpha$ به‌روزرسانی می‌شود [۲۰].


$$L = L_0 + \alpha \sum_{i=1}^3 L_i \quad (2)$$

^۱ Max Pooling

^۲ Mean Absolute Error

^۳ Epoch

^۴ Minibatch Size



شکل ۳: معماری شبکه‌ی UNet پیشنهادی

۳. یافته‌های تحقیق

در این پژوهش از نرم افزارهای Matlab ۲۰۲۱a برای پیش پردازش داده، و python ۳،۱۱ برای آموزش و تست مدل استفاده شد. [پایه‌سازی پروژه بر روی یک سیستم مجهز به کارت گرافیک RTX۳۰۹۰ انجام شد.](#)

شایان ذکر است طریقه‌ی تقسیم‌بندی مجموعه داده به صورت ۷۰٪ متعلق به مجموعه داده‌ی آموزشی، ۱۵٪ متعلق به مجموعه داده‌ی اعتبارسنجی و ۱۵٪ متعلق به مجموعه داده‌ی تست انجام شده است. در این روش تقسیم‌بندی، هیچ نشر اطلاعاتی بین داده‌های آموزش و آزمون وجود ندارد تا مطمئن شویم که روش بدون کالیبراسیون فردی اجرا شده است.

۱-۳. معیارهای ارزیابی

در رگرسیون، معیارهای ارزیابی مختلفی استفاده می‌شوند تا کیفیت مدل رگرسیونی را ارزیابی کنند. در این مقاله از معیارهای ارزیابی [میانگین مربعات خطا \(MSE\)](#)^۱، میانگین خطای مطلق (MAE)^۲، انحراف معیار خطای مطلق (SD)^۳، ضریب تعیین R^2 ^۴، نمودار رگرسیون، نمودار Bland-Altman، معیار استاندارد BHS^۵، معیار AAMI^۶ برای مقایسه‌ی روش اعمال شده با دیگر پژوهش‌های این حوزه و ارائه‌ی نتایج گرفته شده از مدل، بهره گرفته شده است.

^۱ Mean Squared Error

^۲ Mean Absolute Error

^۳ Standard Deviation


^۴ Coefficient of Determination - R-squared

^۵ British Hypertension Society

^۶ Association for the Advancement of Medical Instrumentation

۲-۳. نتایج تخمین فشار خون پیوسته

از آنجا که هدف اولیه‌ی این پژوهش، ارائه‌ی تخمین فشار خون پیوسته از سیگنال ورودی PPG است، در اولین گام از آزمایشهای صورت گرفته، دقت تخمین سیگنال ABP را به صورت کیفی و کمی در این بخش ارائه می‌کنیم. شکل موج PPG و ABP یکی از نمونه‌های ورودی و سیگنال خروجی تولید شده از شبکه‌ی UNet در شکل ۵ نمایش داده شده است. همان‌طور که این شکل نشان می‌دهد، سیگنال فشار خون تخمینی از شبکه‌ی UNet، توانسته تقریب خوبی از سیگنال ABP مینا را به عنوان خروجی نهایی تولید کند. البته در تخمین فشار خون ماکزیم یعنی فشار سیستول دقت کمتری مشاهده می‌شود. از لحاظ کمی، میانگین خطای مطلق سیگنال فشار خون $6/33$ با انحراف میانگین $12/45$ میلی‌متر جیوه است که بیان‌گر موفقیت نسبی روش به کار برده شده در این پژوهش می‌باشد.



شکل ۴: نمایش خروجی شبکه در هر مرحله در معماری UNet پیشنهادی. نمودارها از بالا به پایین به ترتیب نمایش دهنده سیگنال PPG ورودی، خروجی شبکه در تخمین ABP، سیگنال ABP مرجع و مقایسه‌ی خروجی شبکه و سیگنال مرجع می‌باشد.

۳-۳. نتایج تخمین فشار خون سیستول و دیاستول


با توجه به اینکه خروجی شبکه‌ی طراحی شده، سیگنال ABP است، برای ارزیابی مدل می‌بایست مقادیر سیستول و دیاستول برای هر بخش از سیگنال ABP حاصل، محاسبه می‌شد. برای این منظور، مقادیر بیشینه و کمینه سیگنال ABP به ترتیب به عنوان مقادیر سیستول و دیاستول محاسبه شدند.

همان‌طور که در جدول ۲ گزارش شده است، مقدار خطا بر حسب شاخص‌های مختلف در تخمین فشار سیستول بیشتر از خطای تخمین فشار دیاستول و میانگین می‌باشد.

جدول ۲: نتایج تخمین فشار سیستول و دیاستول در معماری UNet پیشنهادی.


	MAE	SD	MSE	R ² -score
SBP	۸.۸۸	۱۱.۰۱	۱۱۲.۶۲	۰.۴۴
DBP	۴.۴۳	۶.۱۸	۳۲.۵۱	۰.۹۴
MAP	۳.۳۲	۴.۱۵	۱۵.۹۳	۰.۹۱

در ادامه به نمایش خطای مطلق هریک از مقادیر سیستول و دیاستول و فشار خون میانگین برای نمونه‌های تست در شکل ۵ پرداختیم تا درک بهتری از نحوه توزیع خطای مطلق حاصل شود. همچنین تعداد نمونه‌های دارای خطای کمتر از ۵، ۱۰، و ۱۵ میلی‌متر جیوه برای محاسبه استاندارد BHS در این نمودارها مشخص شده است. همان‌طور که مشاهده می‌شود، برای فشار خون میانگین و دیاستول، تعداد بسیار محدودی از نمونه‌ها دارای خطای بالاتر از ۱۵ میلی‌متر جیوه هستند.



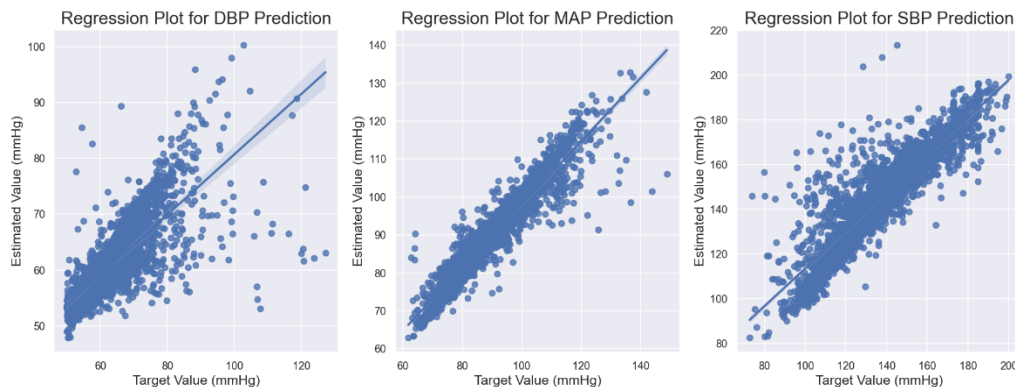
شکل ۵: هیستوگرام خطای مطلق نمونه‌های تست در معماری UNet پیشنهادی. نمودارها به ترتیب از چپ به راست خطای مطلق در تخمین فشار خون سیستول، دیاستول و میانگین را نشان می‌دهد. فراوانی نمونه‌های دارای خطای کمتر از ۵، ۱۰، و ۱۵ میلی‌متر جیوه در این نمودارها با خط چین مشخص شده است.

در شکل ۶ به بررسی یکی دیگر از معیارهای آماری برای ارزیابی مدل پیشنهادی به نام معیار Bland-Altman خواهیم پرداخت تا بهتر بتوانیم پراکندگی و اختلاف بین مقادیر تخمینی فشار خون از نمونه‌های مختلف را بررسی کنیم. همان‌طور که در شکل ۶ ملاحظه می‌شود، خطای تخمین فشار دیاستول، میانگین و سیستول برای ۹۵٪ نمونه‌ها به ترتیب در بازه $[-۱۰:۱۵]$ ، $[-۸:۸]$ و $[-۲۹:۱۳]$ میلی‌متر جیوه قرار دارد. این مقادیر حاکی از آن است که پراکندگی بین مقادیر تخمینی در فشار خون سیستول بیش از دیاستول و میانگین می‌باشد.



شکل ۶: نمودار بلند-آلتمن برای تخمین پارامترهای فشار خون در معماری UNet. شکل‌ها به ترتیب از چپ به راست نمودار بلند-آلتمن در تخمین فشار خون دیاستول، میانگین و سیستول را نشان می‌دهند.

شکل ۷ نمودار رگرسیون در تحلیل داده‌های تخمینی فشار دیاستول، میانگین و سیستول را نشان می‌دهد که بیان‌گر وجود همبستگی بین مقادیر واقعی و مقادیر تخمینی است. در حقیقت شیب خط رگرسیون نشان می‌دهد که چقدر تغییرات در متغیر وابسته را می‌توان به تغییرات متغیر مستقل نسبت داد. در این نمودار، شیب خط رگرسیون برای تخمین فشار خون دیاستول، میانگین و سیستول به ترتیب برابر $۰/۵۳$ ، $۰/۸۳$ و $۰/۸۴$ می‌باشد. خطای استاندارد از دیگر مولفه‌های تحلیل نمودار رگرسیون می‌باشد که نشان می‌دهد چقدر داده‌ها از خط رگرسیون پراکنده هستند. اگر خطای استاندارد کم باشد، نمودار به خوبی با خط رگرسیون هماهنگ است و داده‌ها نزدیک به خط قرار دارند. همان‌طور که از شکل ۷ پیداست، خطای تخمین فشار میانگین کمتر از فشار سیستول و دیاستول است.



شکل ۷: نمودار رگرسیون برای پیش‌بینی پارامترهای فشارخون در معماری UNet. شکل‌ها به ترتیب از چپ به راست نمودار رگرسیون فشار خون دیاستول، میانگین و سیستول را نشان می‌دهند.

۳-۴. ارزیابی نتایج با استانداردهای بین‌المللی

استاندارد BHS عملکرد مدل را برحسب درصد تجمعی خطا درجه بندی می‌کند. این معیار که برای ارزیابی دقت دستگاه‌های اندازه‌گیری فشار خون استفاده می‌شود، برای روش پیشنهادی این مقاله در جدول ۳ نشان داده شده است. همان‌طور که در این جدول گزارش شده است، مقدار خطای سیستول بیشتر از خطای دیاستول بوده و طبق استاندارد BHS، فشار خون دیاستول و میانگین به درجه‌ی A و فشار خون سیستول به درجه‌ی C دست پیدا کرده است. این بدان معناست که مدل پیشنهادی دارای دقت خوبی برای تخمین فشار خون دیاستول و میانگین بوده و می‌تواند برای کاربرد بالینی مورد استفاده قرار بگیرد، اما در مورد تخمین فشار خون سیستول جهت استفاده در بالین می‌بایست بهبود پیدا کند.


در خصوص استاندارد AAMI شرط لازم برای کسب این استاندارد، داشتن داده از حداقل ۸۵ نفر و حداکثر سه بار از یک فرد است. به عبارت دیگر حداقل به ۲۵۵ نمونه داده نیاز است. بر مبنای این استاندارد، دستگاه‌های اندازه‌گیری فشار خون می‌بایست نتایجی را ارائه کنند که در آنها میانگین خطا و انحراف معیار به ترتیب کمتر از ۵ و ۸ میلیمتر جیوه باشد. مطابق جدول ۴، مدل پیشنهادی ما برای فشار خون دیاستول و میانگین الزامات استاندارد AAMI را برآورده می‌کند. برای درک بهتر توزیع خطا در تخمین فشار خون سیستول و دیاستول، هیستوگرام خطای نمونه‌های تست در شکل ۸ نمایش داده شده است. همان‌طور که در این شکل می‌بینیم، میانگین خطا در هر سه شاخص تقریباً صفر بوده مقدار واریانس خطا در فشار خون سیستول اندکی بالاتر از فشار دیاستول و میانگین است.

جدول ۳: گزارش نتایج عددی در قالب استاندارد BHS در معماری UNet پیشنهادی.

		Cumulative Error Percentage		
		≤ 5 mmHg	≤ 10 mmHg	≤ 15 mmHg
Our Results	SBP	۵۸,۸٪	۸۰,۲ %	۸۸,۷٪
	DBP	۸۳,۹٪	۹۵,۰٪	۹۷,۷٪
	MAP	۸۸,۲٪	۹۷,۰٪	۹۸,۹٪
BHS Metric	Grade A	۶۰٪	۸۵٪	۹۵٪
	Grade B	۵۰٪	۷۵٪	۹۰٪
	Grade C	۴۰٪	۶۵٪	۸۵٪

جدول ۴: گزارش نتایج عددی در قالب استاندارد AAMI در معماری UNet پیشنهادی.

		ME	STD
Our Results	SBP	۶,۶۶	۸,۲۶
	DBP	۳,۳۲	۴,۶۳
	MAP	۲,۴۹	۳,۱۱
AAMI Metric		≤ 5	≤ 8



شکل ۸: هیستوگرام خطای نمونه‌های تست در معماری UNet پیشنهادی برای تخمین فشار خون دیاستول (سمت چپ)، فشار خون میاتگین (وسط) و فشار خون سیستول (سمت راست).

۳-۵. بررسی عملکرد مدل بر اساس گروه‌های مختلف فشارخون

در پایان این بخش، برای بررسی بیشتر نتایج بدست آمده از مدل UNet، به طبقه‌بندی فشار خون سیستول و دیاستول به سه گروه فشار خون طبیعی^۱، فشار بالا مستعد بیماری^۲، و فشار خیلی بالا^۳ تقسیم‌بندی کردیم که در جدول ۵ به محدوده‌ی فشار خون مورد نظر اشاره شده است. نتایج این ارزیابی در شکل ۱۰ به نمایش درآمده است. در تخمین فشار خون دیاستول، مدل با دقت خوبی (۹۸٪) قادر به تفکیک طبقه‌ی نرمال شده است، درحالی‌که دقت طبقه‌بندی فشار خون در افراد مستعد بیماری و افراد دارای فشار خون بالا تقریباً در یک محدوده قرار دارد (۴۳٪ در مقابل ۵۰٪). از طرف دیگر، در تخمین فشار خون سیستول، بهترین دقت طبقه‌بندی مربوط به افراد با فشار خون بالا (۹۹٪) بوده، و دقت طبقه‌بندی در افراد مستعد بیماری و افراد نرمال به ترتیب در جایگاه‌های بعدی قرار دارند (۴۳٪ و ۵۶٪).


^۱ Normotension

^۲ Prehypertension

^۳ Hypertension

جدول ۵: محدوده فشار خون سیستول و دیاستول در سه طبقه

وضعیت فشار خون	دیاستول (میلی متر جیوه)	سیستول (میلی متر جیوه)
نرمال	بین ۶۰ تا ۸۰	بین ۸۰ تا ۱۲۰
مستعد فشار خون بالا	بین ۸۰ تا ۹۰	بین ۱۲۰ تا ۱۴۰
فشار خون بالا	بالتر از ۹۰	بالتر از ۱۴۰



شکل ۹: طبقه‌بندی فشار خون دیاستول و سیستول به سه طبقه نرمال، فشار خون مستعد بیماری، فشار خون بالا در معماری UNet پیشنهادی.

۴. بحث و جمع بندی

فشار خون یکی از شاخص‌های مهم سلامتی است که اندازه‌گیری و نظارت مداوم بر آن برای تشخیص و کنترل بیماری‌های قلبی و عروقی ضروری است. روش‌های سنتی اندازه‌گیری فشار خون از طریق فشارسنج‌ها، نیازمند تجهیزات پیچیده و مزاحم هستند. به همین دلیل، استفاده از روش‌های غیرتهاجمی و غیرمستقیم برای تخمین فشار خون مورد توجه قرار گرفته است. سیگنال PPG یکی از روش‌های غیرتهاجمی است که با استفاده از نورسنجی، به اندازه‌گیری تغییرات حجم خون در عروق پیرامونی به صورت غیرمستقیم می‌پردازد. این سیگنال به صورت ضربانی بوده و الگوها و اطلاعات موجود در آن می‌تواند اطلاعاتی درباره‌ی فشار خون فرد را ارائه دهد. در این مقاله، ما به بررسی استفاده از سیگنال PPG برای تخمین فشار خون پیوسته با استفاده از شبکه‌های عصبی یادگیری عمیق پرداختیم. تخمین شکل موج سیگنال فشار خون نسبت به تخمین مقادیر کلی فشار سیستولیک و دیاستولیک **ارجحیت** دارد؛ زیرا شکل موج سیگنال فشار خون، اطلاعات دقیق‌تری درباره‌ی عملکرد قلب و عروق و تغییرات آن در طول زمان در اختیار پزشک قرار می‌دهد که می‌تواند در تشخیص بیماری‌ها و پیگیری وضعیت فشار خون مفید باشد.

در این پژوهش یک مدل یادگیری ماشین با عنوان UNet یک‌بعدی با نظارت عمیق برای تخمین فشار خون پیوسته به کار گرفته شد. استفاده از روش نظارت عمیق معمولاً منجر به افزایش دقت و عملکرد مدل‌ها می‌شود. علت این امر این است که با داشتن خروجی‌های میانی و محاسبه‌ی زیان برای آن‌ها، فرآیند یادگیری بهتر هدایت می‌شود و لایه‌های مخفی مدل به طور مستقل نیز آموزش می‌بینند. این امر می‌تواند موجب استفاده‌ی بهینه‌تر از اطلاعات درون داده‌ها و استخراج ویژگی‌های مفیدتر شود. همچنین، زیان‌های کمکی که از لایه‌های پایین‌تر تا لایه‌های بالاتر با وزن‌های کاهش‌یافته محاسبه می‌شوند، به مدل اجازه می‌دهند به طور متوازن و پیوسته در کل ساختار آموزش ببیند. این مسئله معمولاً باعث افزایش قابل توجه دقت

و کاهش خطاهای کلی مدل می‌شود. با این حال، موفقیت استفاده از نظارت عمیق بستگی به ویژگی‌ها و معماری مدل دارد و در برخی موارد ممکن است تأثیر آن کمتر باشد یا نتایج بهبود چشمگیری نداشته باشند.

مدل ارائه شده بر روی بانک داده‌ی UCI به خطای مطلق میانگین $8/88$ ، $4/43$ و $3/32$ و انحراف معیار $11/01$ ، $6/18$ و $4/15$ میلی‌متر جیوه به ترتیب برای فشار خون سیستول، دیاستول و میانگین دست یافت. نتایج نشان داد اگرچه تخمین فشار سیستول نسبت به دیاستول با خطای بیشتری همراه است، اما ضریب رگرسیون فشار دیاستول کمتر است. این امر می‌تواند ناشی از وجود نقاط پرت در فشار دیاستولی بالا (حدود بالاتر از ۱۰) باشد و در صورتی که این نقاط حذف شوند، نتایج قطعاً تغییر خواهد کرد. شکل ۹، که نتایج طبقه‌بندی گروه‌های فشار خون مختلف را ارائه می‌دهد، این واقعیت را تأیید می‌کند که مدل در تخمین فشار خون دیاستولی در گروه فشار خون بالا (hypertension) از دقت کافی برخوردار نیست.

همان‌طور که در بخش نتایج به آن اشاره شد، براساس استاندارد BHS، فشار خون سیستول به رتبه C، دیاستول به رتبه A و فشار خون میانگین به رتبه A دست پیدا کرد. این نتیجه نشان می‌دهد که مدل مورد پیشنهاد قابلیت قابل توجهی در پیش‌بینی دقیق فشار خون دیاستول و میانگین را دارا است و از این رو برای کاربردهای بالینی مناسب به نظر می‌رسد. با این حال، برای ارزیابی دقیق‌تر فشار خون سیستول، نیازمند تحقیقات بیشتر هستیم.

جدول ۶ نتایج روش پیشنهادی ما را در مقایسه با مطالعات قبلی که روی یک بانک داده‌ی یکسان گزارش شده‌اند، ارائه می‌کند. با توجه به تعداد داده‌ی مورد استفاده در تحقیقات گذشته، تفاوت در روش‌های پیش پردازش سیگنال PPG و تکنیک‌های ارزیابی نتایج، مقایسه‌ی مستقیم روش‌های پردازشی منصفانه نیست. اما می‌توان یک جمع‌بندی از کلیات روش‌های اعمال شده در پژوهش‌های مختلف و موفقیت نسبی آنها در تخمین فشار خون از روی سیگنال PPG به عنوان ورودی مدل داشت. همان‌طور که در این جدول ملاحظه می‌شود، در تحقیقات مبتنی بر کالیبراسیون فردی، که بخشی از داده‌ی یک شخص در تعلیم مدل رگرسیون استفاده می‌شود، نتایج به صورت چشمگیری بهبود پیدا می‌کند. مطالعات بسیاری بر تأثیر کالیبراسیون فردی در بهبود نتایج تأکید کرده‌اند [۲۱] [۲۲] اما با توجه به محدودیت استفاده از چنین تکنیکی در کاربردهای بالینی، بسیاری از پژوهش‌ها سعی در افزایش دقت تخمین پارامترهای فشار خون بدون تکیه بر کالیبراسیون فردی داشته‌اند. در مقاله‌ی [۲۳] که مشابه کار ما از تمام داده‌های بانک داده UCI استفاده کرده و نتایج آن بر اساس عدم کالیبراسیون فردی بوده است، محدوده‌ی خطای گزارش شده مشابه نتایج ما بوده است. البته در مقاله‌ی مذکور از روش‌های شناسایی نقاط کلیدی سیگنال PPG، استخراج ویژگی و مدل سنتی رگرسیون استفاده شده است که به طور کلی ممکن است در مقایسه با تکنیک‌های یادگیری عمیق (مدل پیشنهادی این تحقیق) قدرت انعطاف‌پذیری کمتری در مواجهه با داده‌های جدید داشته باشد. در حقیقت روش‌های سنتی یادگیری ماشین به شدت به مشخصات ساختاری داده‌ها وابسته هستند و در صورت تغییر ساختار داده، ممکن است نیاز به تنظیم مجدد و حتی طراحی مجدد ویژگی‌ها داشته باشند.

در مقاله‌ی [۱۳] نیز که تمام داده‌های بانک داده UCI مورد تحلیل قرار گرفته‌اند، نتایج مطلوبی گزارش شده است. در این مقاله از دو شبکه‌ی UNet به عنوان شبکه‌های تخمین و تصحیح استفاده شده است. به این ترتیب، که شبکه‌ی UNet ابتدا با بهره‌گیری از سیگنال PPG به عنوان ورودی، یک تخمین اولیه از سیگنال فشار خون ارائه می‌دهد. در مرحله‌ی بعد، یک شبکه‌ی MultiResUNet با استفاده از سیگنال فشار خون واقعی به عنوان ورودی، شکل سیگنال فشار خون تخمینی را اصلاح می‌کند. از نظر شباهت مدل پیشنهادی ما به مدلی که در این مقاله ارائه شده است، باید اشاره کرد که در پژوهش ما از یک شبکه‌ی عمیق UNet با تعداد لایه‌های کمتر نسبت به مقاله‌ی مذکور استفاده شده است، در حالی که در مقاله‌ی [۱۳] از دو شبکه‌ی UNet با تعداد لایه‌های بیشتر بهره‌گیری شده است. همچنین، در روش پیشنهادی ما تغییراتی در طراحی تابع ضرر مدل اعمال شده است (که در بخش ۲-۳ به آن اشاره شد) که در بهبود دقت نهایی مؤثر بوده است. بنابراین، مدل پیشنهادی ما دارای پیچیدگی محاسباتی کمتر و سرعت بالاتری است.

به علاوه، در مقایسه با سایر مقالات، که بعضاً نتایج بهتری را گزارش کرده‌اند، به نظر می‌رسد با توجه به کاهش تعداد نمونه‌های داده، حذف داده‌های پرت انجام شده باشد. همچنین تعدادی از آنان دارای کالیبراسیون فردی بوده‌اند که باعث بهبود دقت می‌شود.

در مجموع، همان‌طور که در جدول ۶ مشاهده می‌شود، نتایج این تحقیق با توجه به استفاده از حجم بالای داده و عدم استفاده از تکنیک کالیبراسیون فردی، به نتایج مطلوبی در قیاس با نتایج سایر محققین دست پیدا کرده است.

جدول ۶: خلاصه‌ای از اطلاعات مهم پژوهش‌های پیشین روی بانک داده UCI (NA به معنی در دسترس نبودن اطلاعات می باشد).

کالیبراسیون	معیار BHS		خطا (MAE)		تعداد داده	مرجع
	DBP	SBP	DBP (mmHg)	SBP (mmHg)		
NA	NA	NA	۱۰,۷۷	۱۷,۰۸	۸۳۸۰	[۲۴]
No	A	B	۳,۴۵	۵,۷۳	۱۲۰۰۰	[۱۳]
No	A	C	۲,۴۳	۳,۹۷	۱۳۲۳	[۲۵]
Yes	A	B	۳,۳۸	۵,۳۲	۱۹۱۲	[۲۶]
NA	A	A	۲,۳۰	۳,۹۷	۱۵۵۷	[۲۷]
No	A	C	۴,۱۷	۸,۲۲	۱۲۰۰۰	[۲۳]
No	A	B	۳,۳۶	۵,۵۹	۱۱۵۴۶	[۲۸]
Yes	A	A	۲,۸۱	۳,۷۰	۱۲۱۶	[۲۹]
NA	A	A	۱,۵۸	۳,۰۵	NA	[۳۰]
NA	A	A	۲,۲۳	۳,۲۱	۹۰۰۰	[۳۱]
Yes	NA	NA	۵,۵۷	۷,۱۵	۱۶۲۰	[۲۱]
NA	A	A	۲,۳۹	۳,۹۶	۳۱۸۳	[۳۲]
NA	A	A	۲,۴۱	۴,۰۵	۵۲۸۹	[۳۳]
No	A	C	۴,۴۳	۸,۸۸	۱۲۰۰۰۰	تحقیق ما

۵. منابع

- [۱] L. Peter, N. Noury, and M. Cerny, "A review of methods for non-invasive and continuous blood pressure monitoring: Pulse transit time method is promising?," *IRBM*, vol. ۳۵, no. ۵, pp. ۲۷۱–۲۸۲, ۲۰۱۴.
- [۲] K. Qin, W. Huang, T. Zhang, and S. Tang, "Machine learning and deep learning for blood pressure prediction : a methodological review from multiple perspectives," in *Artificial Intelligence Review*, Springer, ۲۰۲۲, pp. ۸۰۹۵–۸۱۹۶.
- [۳] س.س. موسوی. "طراحی و ساخت هولتر فشارخون مبتنی بر تلفن همراه با به کارگیری سیگنال های الکتروکاردیوگرام و فوتوپلتیسموگرافی،" زنجان، ۱۳۹۷.
- [۴] R. Mukkamala, J. Hahn, and A. Chandrasekhar, "Photoplethysmography in noninvasive blood pressure monitoring," in *Photoplethysmography Technology, Signal Analysis and Applications*, Academic Press, ۲۰۲۲, pp. ۳۵۹–۴۰۰.
- [۵] X. DUAN, "The Analysis of Photoplethysmography Signal: Investigating the Current Methods of Cuff-Less Blood Pressure Monitoring," *Vrije Universiteit Brussel & Universiteit Gent*, ۲۰۲۱.
- [۶] C. Landry, S. Peterson, and A. Arami, "Nonlinear Dynamic Modelling of the Blood Pressure Waveform: Towards an Accurate Cuffless Monitoring System," *IEEE Sens J*, vol. ۲۰, pp. ۵۳۶۸–۵۳۷۸, ۲۰۲۰.

م. شهایی، و. نفیسی، "تخمین بدون کاف فشارخون مبتنی بر ویژگی‌های زمانی سیگنال نبض"، *پردازش علائم و داده ها، صفحات ۱۰۳-۱۱۳، ۱۳۹۷.*

[۷]

- [۸] S. S. Mousavi, M. Charmi, M. Firouzmand, and M. Hemmati, "Design and Manufacturing a Mobile-Based Ambulatory Monitoring of Blood Pressure Using Electrocardiogram and Photoplethysmography Signals," University of Zanjan, Zanjan, ۲۰۱۸.
- [۹] S. Mahmud *et al.*, "A Shallow U-Net Architecture for Reliably Predicting Blood Pressure (BP) from Photoplethysmogram (PPG) and Electrocardiogram (ECG) Signals," *sensors*, vol. ۲۲, ۲۰۲۲.
- [۱۰] D. U. Jeong and K. M. Lim, "Combined deep CNN – LSTM network - based multitasking learning architecture for noninvasive continuous blood pressure estimation using difference in ECG - PPG features," *Sci Rep*, no. ۰۱۲۳۴۵۶۷۸۹, pp. ۱-۸, ۲۰۲۱, doi: ۱۰.۱۰۳۸/s۴۱۵۹۸-۰۲۱-۹۲۹۹۷-۰.
- [۱۱] Y. H. Li, L. N. Harfiya, K. Purwandari, and Y. Der Lin, "Real-time cuffless continuous blood pressure estimation using deep learning model," *Sensors (Switzerland)*, vol. ۲۰, no. ۱۹, pp. ۱-۱۹, ۲۰۲۰, doi: ۱۰.۳۳۹۰/s۲۰۱۹۵۶۰۶.
- [۱۲] S. González, W. Hsieh, and T. P. Chen, "A benchmark for machine- learning based non-invasive blood pressure estimation using photoplethysmogram," *Sci. Rep.*, vol. ۱۰, no. ۱۴۹, pp. ۱-۱۶, ۲۰۲۳.
- [۱۳] N. Ibtehaz *et al.*, "PPG۲ABP : Translating Photoplethysmogram (PPG) Signals to Arterial Blood Pressure (ABP) Waveforms," *Bioengineering*, vol. ۹, no. ۱۱, ۲۰۲۲.
- [۱۴] S. Lee, M. Lee, and J. Y. Sim, "DSE-NN: Deeply Supervised Efficient Neural Network for Real-Time Remote Photoplethysmography," *Bioengineering*, vol. ۱۰, no. ۱۲, ۲۰۲۳.
- [۱۵] S. Ali, J. Li, Y. Pei, and K. U. Rehman, "A Multi-module ۳D U-Net Learning Architecture for Brain Tumor Segmentation A Multi-module ۳D U-Net Learning Architecture for Brain Tumor," in *Data Mining and Big Data*, Springer, ۲۰۲۲, pp. ۵۷-۶۹.
- [۱۶] Y. Li, K. Li, and X. Wang, "Deeply-Supervised CNN Model for Action Recognition with Trainable Feature Aggregation," in *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence(IJCAI)*, ۲۰۱۷, pp. ۸۰۷-۸۱۳.
- [۱۷] G. Dheeru and D. Casey, "UCI Machine Learning Repository."
- [۱۸] M. Kachuee, M.M. Kiani, H. Mohammadzade, and M. Shaban, "Cuffless blood pressure estimation algorithms for continuous health-care monitoring," *IEEE Trans. Biomed. Eng.*, vol. ۶۴, pp. ۸۵۹-۸۶۹, ۲۰۱۶.
- [۱۹] D. P. Kingma and L. Ba, "Adam: A method for stochastic optimization," in *3rd International Conference for Learning Representations*, San Diego, ۲۰۱۵.
- [۲۰] P. Lv, J. Wang, X. Zhang, and Ch. Shi, "Deep supervision and atrous inception-based U-Net combining CRF for automatic liver segmentation from CT," *Sci. Rep.*, vol. ۱۲, no. ۱۶۹۹۵, ۲۰۲۲.
- [۲۱] J. Cheng, Y. Xu, R. Song, Y. Liu, Ch. Li, and X. Chen, "Prediction of arterial blood pressure waveforms from photoplethysmogram signals via fully convolutional neural networks," *Comput. Biol. Med.*, vol. ۱۳۸, ۲۰۲۱.

- [۲۲] م. قنواتی، س. ف. مولایی زاده، و م. نویدی، "یک روش شخصی سازی شده برای تخمین فشارخون بدون کاف از یک سنسور PPG مبتنی بر یادگیری انتقالی عمیق "سی/امین کنفرانس ملی و هشتمین کنفرانس بین المللی مهندسی زیست پزشکی/ایران، تهران، ۱۴۰۲.
- [۲۳] N. Hasanzadeh and M.M. Ahmadi, "Blood pressure estimation using photoplethysmogram signal and its morphological features," *IEEE Sens. J.*, vol. ۲۰, no. ۸, pp. ۴۳۰۰–۴۳۱۰, ۲۰۱۹.
- [۲۴] S. Bose S and A. Kandaswamy, "Sparse characterization of PPG based on K- SVD for beat-to-beat blood pressure prediction," *Biomedical Research*, vol. ۲۹, no. ۴, pp. ۸۳۵–۸۴۳, ۲۰۱۸.
- [۲۵] S. S. Mousavi et al., "Blood pressure estimation from appropriate and inappropriate PPG signals using a whole-based method," *Biomed Signal Process Control*, vol. ۴۷, pp. ۱۹۶–۲۰۶, ۲۰۱۹.
- [۲۶] S. Baek et al., "End-to-End Blood Pressure Prediction via Fully Convolutional Networks," *IEEE Access*, vol. ۷, pp. ۱۸۵۴۵۸–۱۸۵۴۶۸, ۲۰۱۹.
- [۲۷] M. Panwar, A. Gautam, D. Biswas, and A. Acharyya, "PP-Net: a deep learning framework for PPG-based blood pressure and heart rate estimation," *IEEE Sens. J.*, vol. ۲۰, no. ۱۷, pp. ۱۰۰۰۰–۱۰۰۱۱, ۲۰۲۰.
- [۲۸] M. Rong and K. Li, "A multi-type features fusion neural network for blood pressure prediction based on photoplethysmography," *Biomed Signal Process Control*, vol. 68, p. 102772, 2021, vol. ۶۸, ۲۰۲۱.
- [۲۹] Y. Qiu et al., "Blood pressure estimation based on composite neural network and graphics information," *Biomed. Signal Process. Control*, vol. ۷۰, no. ۱۰۳۰۰۱, ۲۰۲۱.
- [۳۰] A. B. Malayeri and M. B. Khodabakhshi, "Concatenated convolutional neural network model for cuffless blood pressure estimation using fuzzy recurrence properties of PPG signals," *Sci. Rep.*, vol. ۱۲, no. ۶۶۳۳, ۲۰۲۲.
- [۳۱] Y-C. Hsu, Y-H. Li, C-C. Chang, and L. N. Harfiya, "Generalized deep neural network model for cuffless blood pressure estimation with photoplethysmogram signal only," *Sensors*, vol. ۲۰, no. ۱۹, ۲۰۲۰.
- [۳۲] Z. Li and W. He, "A continuous blood pressure estimation method using photoplethysmography by GRNNbased model," *Sensors*, vol. ۲۱, no. ۲۱, ۲۰۲۱.
- [۳۳] L. N. Harfya, C-C. Chang, and Y-H. Li, "Continuous blood pressure estimation using exclusively photoplethysmography by LSTM-based signal-to-signal translation," *Sensors*, vol. ۲۱, no. ۹, ۲۰۲۱.